Stream processing et SQL

Bruno Bonnin

```
@_bruno_b_
#devoxxfr
```

About me

























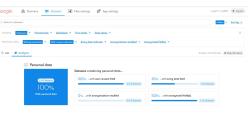
Data Fabric



Data Governance



GDPR



Streams

Flot continue et sans fin de données

Sources:

- IoT
- Monitoring
- Click streams

- Finance
- Jeux en ligne
- ...

Pourquoi SQL in 2017?

C'est un standard!

Largement adopté par tous (même si on peut/veut l'éviter...)

- o Développeur
- Architecte data
- Data scientist
- 0 ...



Les streams sont des données comme les autres!

Alors pourquoi ne pas utiliser SQL pour les requêter?

SQL vs. Stream processing

Relational Algebra / SQL	Stream Processing
Relations (or tables) are bounded (multi-)sets of tuples.	A stream is an infinite sequences of tuples.
A query that is executed on batch data (e.g., a table in a relational database) has access to the complete input data.	A streaming query cannot access all data when is started and has to "wait" for data to be streamed in.
A batch query terminates after it produced a fixed sized result.	A streaming query continuously updates its result based on the received records and never completes.

Source: https://ci.apache.org/projects/flink/flink-docs-release-1.3/dev/table/streaming.html

SQL et Stream processing







Apache Calcite

Apache Calcite

- Catalogue des metadatas
- Parsing SQL
- Validation des requêtes SQL
- Optimisation des requêtes SQL
 - Plan d'exécution



Adaptateurs pour différentes sources de données (MongoDB, Elastic, ...)

L'exécution des requêtes est à la charge du système utilisant Calcite

Pour les **streams**: définition d'un minimum de mots-clés et de fonctions pour les requêter

THE keyword!

SELECT STREAM * FROM weblogs;

weblogs est un stream

Requêtes ne se terminant pas

Sur quelles données ? de maintenant à ...

```
SELECT STREAM url, status_code, nb_bytes FROM weblogs;
SELECT STREAM url, nb_bytes FROM weblogs WHERE status = 500;
```

Jointure avec une table

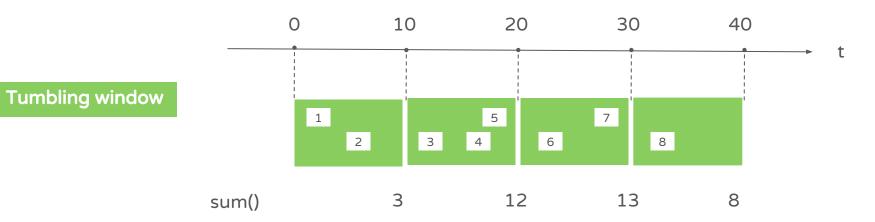
SELECT STREAM c.id_pizza, p.prix
FROM commandes_pizza AS c
JOIN pizzas AS p
ON c.id_pizza = p.id_pizza;

Simple pour une table qui ne change pas

Et si la table bouge?

Une solution: stocker l'historique dans la table pour l'utiliser dans la requête SELECT STREAM c.id_pizza, p.prix
FROM commandes_pizza AS c
JOIN pizzas AS p
ON c.id_pizza = p.id_pizza
AND c.rowtime
BETWEEN p.dateDebut AND p.dateFin;

Windowing



```
SELECT STREAM

TUMBLE_END(rowtime, INTERVAL '10' SECOND),

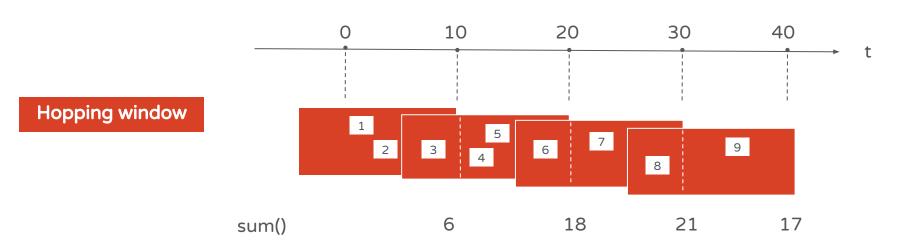
url,

SUM(nb_bytes) AS total_bytes

FROM weblogs

GROUP BY TUMBLE(rowtime, INTERVAL '10' SECOND), url;
```





```
SELECT STREAM

HOP_END (rowtime, INTERVAL '10' SECOND, INTERVAL '15' SECOND) AS rowtime,

SUM (nb_bytes) AS total_bytes

FROM weblogs

GROUP BY HOP (rowtime, INTERVAL '5' SECOND, INTERVAL '10' SECOND);
```

Démo

https://github.com/bbonnin/talk-stream-processing-et-sql

Que préférez-vous?

```
final Table table = tableEnv
  .fromDataStream(dataset,
    "ts, ip address, url, status, nb bytes, rowtime.rowtime" )
  .window(
    Tumble
      . over("10.second").on("rowtime").as("tenSecWindow"))
  .groupBy("tenSecWindow, url")
  .select(
     "url, tenSecWindow.end as time, url.count as nb requests" );
tableEnv.toAppendStream(table, Row.class).print();
execEnv.execute();
```

Que préférez-vous?

```
tableEnv.registerDataStream("weblogs", dataset,
       "ts, ip address, url, status, nb bytes, rowtime.rowtime");
final String query =
       "SELECT url, " +
            TUMBLE END (rowtime, INTERVAL '10' SECOND), " +
            COUNT(*) AS nb requests " +
       "FROM weblogs " +
       "GROUP BY TUMBLE (rowtime, INTERVAL '10' SECOND), url";
final Table table = tableEnv.sql(query);
tableEnv.toAppendStream(table, Row.class).print();
execEnv.execute();
```

Conclusion

La partie stream de Calcite offre beaucoup d'autres possibilités comme les jointures entre streams, update/delete/insert, ...

Détails: https://calcite.apache.org/docs/stream.html

Tout n'est pas implémenté!

Mais le but est de faire avancer le standard SQL.

Le SQL permet de réunir tous les acteurs autour d'un outil commun pour traiter les données, streams ou pas !

Merci!

```
@_bruno_b_
#devoxxfr
```

Group by, order by: quelques contraintes

SELECT STREAM status count(*) FROM weblogs
GROUP B status;

Non autorisé par Calcite

Le GROUP BY doit inclure une valeur monotone (par ex, rowtime)

SELECT STREAM status, count(*) FROM weblogs
GROUP BY rowtime, status;